

Universidade Tecnológica Federal do Paraná

Nome da equipe: Data BIT

Membros:

Denise Lins

Luiz Fernando de Barros Caixeta

Link para o repositório:

<<https://gitlab.com/luizfbcaixeta/IntroCD>>

Relação entre ocorrências registradas pela Guarda Municipal e indicadores socioeconômicos nos bairros de Curitiba

1 Extração e manipulação da base de dados

Este trabalho tem como objetivo analisar a distribuição espacial e temporal das ocorrências registradas pela Guarda Municipal de Curitiba, por meio da base SIGESGUARDA, relacionando esses registros a indicadores socioeconômicos dos bairros da cidade. Para isso, serão utilizados dados dos censos demográficos de 2010 e 2022 do IBGE, considerando variáveis como população, rendimento médio do responsável pelo domicílio, taxa de alfabetização e taxa de analfabetismo.

A base do SIGESGUARDA foi tratada para transformar as descrições textuais das ocorrências, presentes nas colunas `NATUREZAX_DESCRICA0` ($x \in [1, 5]$), em variáveis categóricas booleanas. A partir dessas descrições, as ocorrências foram classificadas em grupos como crimes violentos, atendimentos operacionais ou assistenciais, acidentes de trânsito, acidentes naturais, crimes patrimoniais, crimes contra a administração pública, crimes relacionadas à honra ou discriminação, ocorrências envolvendo crianças e adolescentes, fraudes documentais, drogas e substâncias, ordem pública, risco estrutural, produtos perigosos, pessoas desaparecidas e materiais ou objetos.

Além disso, foram realizadas transformações para padronizar os nomes dos bairros e criar variáveis temporais, permitindo agregação das ocorrências por bairro e ano. Dos dados socioeconômicos do IBGE incorporados, foram extraídas informações de população, renda e alfabetização por bairro. O dicionário de dados das bases está disponível na documentação do projeto. Ao final do tratamento, a base consolidada passou a contar com 609.993 linhas e 52 colunas, abrangendo registros no período de 01/01/2009 e 31/12/2025.

Como os dados populacionais e socioeconômicos dos bairros de Curitiba estão disponíveis apenas para os anos censitários de 2010 e 2022, foi necessário estimar os valores para os anos intercensitários. Para os anos entre 2010 e 2022, utilizou-se interpolação linear, estimando anualmente a população total, a população com mais de 15 anos, a quantidade de pessoas alfabetizadas, enquanto os indicadores derivados, como a taxa de alfabetização e o rendimento nominal médio do responsável pelo domicílio em salários mínimos não foram interpolados, mas sim recalculados com base nos resultados da interpolação para os anos do intervalo censitário. Para os anos fora do intervalo censitário, isto é, 2009 e 2023 a 2025, aplicou-se extrapolação linear, permitindo assim a comparação anual entre as ocorrências registradas e os indicadores socioeconômicos estimados para cada bairro.

Essa metodologia foi inspirada no procedimento utilizado por Silva et al. (2020), no qual os autores estimaram populações em anos intercensitários por interpolação linear e, para o período posterior ao último censo disponível, aplicaram extrapolação linear.

O passo a passo da extração está disponível na documentação do projeto.¹

2 Análise exploratória dos dados

Para a análise de dados foram definidas métricas que permitiram comparar os bairros de forma equilibrada. Se utilizássemos apenas valores absolutos, isso poderia elevar as interpretações equivocadas, já que bairros mais populosos tendem naturalmente a apresentar um número maior de ocorrências. Assim, além das contagens absolutas, serão utilizadas métricas normalizadas pela população, permitindo comparações mais adequadas entre bairros de diferentes tamanhos.

¹ Disponível em: https://gitlab.com/luizfbcaixeta/IntroCD/-/blob/master/02%20-%20Analise%20exploratoria/COMO_USAR.md?ref_type=heads.

2.1 Cálculo das métricas de ocorrência

Para a análise, foi calculado o total de ocorrências registradas em cada bairro, conforme a divisão territorial apresentada pelo IPPUC no perfil físico-territorial e socioeconômico dos 75 bairros de Curitiba². Em seguida, para permitir a comparação entre bairros com diferentes tamanhos populacionais, calculou-se a taxa de ocorrências por 10 mil habitantes para cada bairro b no ano i , dada por:

$$\text{taxa_total_ocorrencias}_{b,i} = \frac{\text{total_ocorrencias}_{b,i}}{\text{populacao_estimada}_{b,i}} \times 10.000 \quad (1)$$

Essa taxa representa o número de ocorrências registradas a cada 10 mil habitantes, reduzindo o efeito do tamanho populacional na comparação entre bairros e anos. Além da **taxa_total_ocorrencias**, o mesmo procedimento foi aplicado às demais categorias analisadas, incluindo crimes violentos, atendimentos operacionais e assistenciais, acidentes de trânsito, acidentes naturais, crimes patrimoniais, crimes contra a administração pública, crimes relacionados à honra ou discriminação, ocorrências envolvendo crianças e adolescentes, fraudes documentais, drogas e substâncias, ordem pública, risco estrutural, explosivos e produtos perigosos, pessoas desaparecidas e materiais ou objetos.

A Figura 1 apresenta a evolução temporal das principais taxas de ocorrência por tipo em Curitiba. Observa-se que os atendimentos operacionais e assistenciais apresentam forte crescimento entre 2019 e 2021, seguido de queda nos anos posteriores. Já os acidentes de trânsito passam a crescer de forma mais acentuada a partir de 2020, tornando-se uma das categorias com maior taxa nos anos finais da série. As demais categorias, como crimes violentos, crimes patrimoniais, drogas e substâncias e ordem pública, apresentam valores mais baixos e variações menos intensas ao longo do período analisado.




Figura 1 – Taxa de ocorrências por tipo a cada 10 mil habitantes em Curitiba, entre 2009 e 2025.

2.2 Aumento da taxa de ocorrências relacionadas a crimes violentos para 10 mil habitantes por ano

Também avaliamos quais bairros apresentaram maior crescimento na taxa de crimes violentos ao longo dos anos. Para isso, os dados foram ordenados por bairro e ano, permitindo

² Disponível em: <<https://ippuc.org.br/perfil-fisico-territorial-e-socioeconomico-75-bairros-de-curitiba-2>>.

calcular a variação anual da taxa de crimes violentos em cada bairro. Essa variação foi obtida pela diferença entre a taxa observada em determinado ano e a taxa registrada no ano anterior:

$$\Delta T_{b,t} = T_{b,t} - T_{b,t-1} \quad (2)$$

em que $T_{b,t}$ representa a taxa de crimes violentos por 10 mil habitantes no bairro b no ano t . Em seguida, calculou-se o aumento médio anual da taxa de crimes violentos para cada bairro:

$$\bar{\Delta T}_b = \frac{1}{n_b - 1} \sum_{t=2}^{n_b} \Delta T_{b,t} \quad (3)$$

em que n_b corresponde ao número de anos observados para o bairro b . A partir desse cálculo, foram identificados os dez bairros com maior aumento médio anual na taxa de crimes violentos.

A Figura 2 mostra que o Jardim Botânico se destaca como o bairro com as maiores taxas de crimes violentos por 10 mil habitantes ao longo da série, especialmente a partir de 2013, atingindo seu pico em 2021. O Prado Velho também apresenta aumento expressivo até 2016, seguido de queda gradual nos anos posteriores. Já bairros como Taboão e Batel registram oscilações pontuais, com picos em anos específicos, enquanto os demais bairros mantêm taxas mais baixas e variações menos intensas. De modo geral, o gráfico indica que o crescimento médio anual é influenciado tanto por tendências persistentes quanto por aumentos concentrados em determinados períodos.




Figura 2 – Taxa de ocorrências por tipo a cada 10 mil habitantes em Curitiba, entre 2009 e 2025.

2.3 Aumento da taxa de ocorrências relacionadas de ocorrências relacionadas a drogas para 10 mil habitantes por ano

O mesmo foi feito para ocorrências relacionadas a drogas. A Figura 3 indica que o bairro São Francisco apresenta comportamento bastante discrepante, com taxas muito superiores às dos demais bairros, especialmente nos picos observados em 2011, 2013 e 2019. Essa diferença comprime visualmente as demais séries no gráfico, dificultando a comparação entre elas. Ao remover São Francisco da visualização, observa-se que os outros bairros possuem valores mais baixos e comportamento mais oscilatório, sem uma tendência contínua de crescimento ao longo de todo o período. Alguns casos apresentam aumentos pontuais, como Prado Velho em 2013 e

entre 2021 e 2022, Batel entre 2017 e 2018 e em 2022, e Guabirota em 2020. Dessa forma, os dados sugerem que o aumento das ocorrências relacionadas a drogas e substâncias não ocorre de maneira uniforme entre os bairros, mas é marcado por variações localizadas e episódios específicos de crescimento.




Figura 3 – Evolução temporal das ocorrências nos bairros de Curitiba com maior aumento médio anual, entre 2009 e 2025.

2.4 Métricas temporais

A Figura 4 apresenta a distribuição das principais categorias de ocorrência por período do dia. Observa-se que os atendimentos operacionais e assistenciais concentram os maiores volumes, principalmente no período da tarde, seguido pela manhã e pela noite. Os acidentes de trânsito também são mais frequentes à tarde, com queda expressiva durante a madrugada. Já os crimes violentos e patrimoniais apresentam maior concentração no período da noite, indicando uma possível relação entre esses tipos de ocorrência e horários de menor circulação formal ou maior vulnerabilidade urbana. As ocorrências contra a ordem pública, por sua vez, mostram distribuição mais equilibrada, com destaque para a madrugada e a noite.




Figura 4 – Distribuição das ocorrências por período do dia e tipo selecionado em Curitiba.

2.5 Relação entre renda histórica média, crimes violentos e drogas

Para analisar a relação entre condições socioeconômicas, violência urbana e ocorrências relacionadas a drogas, foi calculada a renda histórica média de cada bairro ao longo do período observado. Inicialmente, obteve-se a renda média anual de cada bairro, expressa em salários mínimos, e, em seguida, calculou-se a média desses valores ao longo dos anos disponíveis. Essa métrica foi utilizada como uma medida sintética da condição socioeconômica histórica dos bairros.

Com base na renda histórica média, os bairros foram classificados em três grupos: menor renda histórica, renda histórica intermediária e maior renda histórica. Essa classificação permite

comparar a distribuição das taxas médias de crimes violentos e de ocorrências relacionadas a drogas entre bairros com diferentes perfis socioeconômicos. A Tabela 1 apresenta exemplos dessa classificação.

Tabela 1 – Exemplos de classificação dos bairros segundo a renda histórica média

Nome do bairro	Renda histórica média (SM)	Grupo
Caximba	1.54	Menor renda histórica
São Miguel	1.86	Menor renda histórica
...	...	...
Hauer	4.18	Renda histórica intermediária
Taboão	4.22	Renda histórica intermediária
...	...	...
Mossunguê	12.78	Maior renda histórica
Batel	13.77	Maior renda histórica

Em seguida, foram calculadas, para cada bairro, a taxa média de crimes violentos e a taxa média de ocorrências relacionadas a drogas e substâncias, ambas por 10 mil habitantes. A Figura 5 apresenta a relação entre essas taxas e a renda histórica média dos bairros.




Figura 5 – Relação entre renda histórica média e taxa média de crimes violentos e de ocorrências relacionadas a drogas/substâncias por 10 mil habitantes nos bairros de Curitiba.

Os resultados indicam que não há uma relação linear evidente entre renda histórica média e as taxas analisadas. No caso dos crimes violentos, observa-se maior dispersão nos bairros de renda intermediária e maior renda, com alguns pontos apresentando taxas elevadas, enquanto os bairros de menor renda concentram-se principalmente em valores baixos e intermediários. Para as ocorrências relacionadas a drogas e substâncias, a maior parte dos bairros também apresenta taxas reduzidas, mas há casos pontuais com valores elevados, inclusive em bairros de renda intermediária e alta. Assim, os resultados sugerem que a renda histórica média, isoladamente, não explica a distribuição dessas ocorrências, sendo necessário considerar outros fatores territoriais, populacionais e urbanos.

2.6 Relação entre alfabetização, crimes violentos e drogas

A mesma estratégia foi aplicada para a alfabetização histórica média, calculada a partir da porcentagem média de pessoas alfabetizadas com 15 anos ou mais em cada bairro. Com base nessa métrica, os bairros foram classificados em três grupos: menor alfabetização, alfabetização intermediária e maior alfabetização. Em seguida, foram comparadas as taxas médias de crimes violentos e de ocorrências relacionadas a drogas/substâncias por 10 mil habitantes, conforme apresentado na Figura 6.




Figura 6 – Relação entre alfabetização histórica média e taxa média de crimes violentos e de ocorrências relacionadas a drogas/substâncias por 10 mil habitantes nos bairros de Curitiba.

Os resultados indicam que não há uma relação linear evidente entre alfabetização histórica média e as taxas analisadas. No caso dos crimes violentos, bairros com maior alfabetização apresentam, em geral, taxas mais baixas, embora existam pontos com valores elevados. Para as ocorrências relacionadas a drogas/substâncias, observa-se maior concentração de valores baixos em todos os grupos, com alguns casos discrepantes em bairros de menor, intermediária e maior alfabetização. Assim, a alfabetização, isoladamente, não parece explicar a distribuição dessas ocorrências.

3 Perguntas de pesquisa e hipóteses

Com base na análise exploratória realizada, este trabalho busca responder perguntas relacionadas à distribuição espacial, temporal e socioeconômica das ocorrências registradas pela SIGESGUARDA.

3.1 Pergunta 1

Indicadores socioeconômicos, como renda histórica média e alfabetização, estão associados às taxas de crimes violentos e de ocorrências relacionadas a drogas nos bairros de Curitiba?

Hipóteses:

- Bairros com menor renda histórica média podem apresentar maiores taxas de crimes violentos e de ocorrências relacionadas a drogas/substâncias, considerando que condições socioeconômicas mais vulneráveis podem estar associadas a maiores níveis de exposição a conflitos urbanos, precariedade territorial e menor acesso a serviços públicos.
- Bairros com menor taxa histórica de alfabetização podem apresentar maiores taxas dessas ocorrências, uma vez que a alfabetização pode funcionar como um indicador indireto de desigualdade social, acesso à educação e condições de inserção socioeconômica da população.

A análise exploratória indicou, entretanto, que alguns bairros de renda intermediária ou alta também apresentam taxas elevadas dessas ocorrências. Isso sugere que outros fatores, como circulação de pessoas, presença de comércios, centralidade urbana, fiscalização e dinâmica territorial, também podem influenciar a distribuição dos registros. Assim, a hipótese principal é que renda e alfabetização ajudam a explicar parte da variação entre os bairros, mas não

são suficientes, isoladamente, para explicar a distribuição espacial dos crimes violentos e das ocorrências relacionadas a drogas.

Como próxima etapa, pretende-se aplicar o teste de *Kruskal-Wallis*, um teste estatístico não paramétrico utilizado para comparar três ou mais grupos independentes. Ele é adequado para esta análise porque os bairros foram organizados em grupos de renda e alfabetização, e as taxas analisadas apresentam oscilações, valores discrepantes e não necessariamente seguem uma distribuição normal. O teste será utilizado para verificar se existem diferenças estatisticamente significativas nas taxas médias de crimes violentos e de ocorrências relacionadas a drogas/substâncias entre os grupos de menor, intermediária e maior renda histórica, bem como entre os grupos de menor, intermediária e maior alfabetização.

3.2 Pergunta 2

Quais bairros apresentam maior crescimento nas taxas de crimes violentos e de ocorrências relacionadas a drogas ao longo do tempo?

Hipóteses:

- O crescimento das taxas de crimes violentos e de ocorrências relacionadas a drogas não ocorre de maneira uniforme entre os bairros de Curitiba, mas se concentra em determinados territórios.
- Alguns bairros podem apresentar crescimento mais persistente ao longo da série histórica, indicando uma tendência de aumento gradual das ocorrências. Outros, por outro lado, podem apresentar apenas picos pontuais em anos específicos, sem uma trajetória contínua de crescimento.

A análise exploratória reforça a hipótese de que o crescimento das ocorrências não ocorre de forma homogênea entre os bairros. Nos crimes violentos, o Jardim Botânico apresentou as maiores taxas ao longo da série, especialmente a partir de 2013, com pico em 2021. O Prado Velho também teve aumento expressivo até 2016, seguido de queda, enquanto bairros como Taboão e Batel apresentaram oscilações mais pontuais, com picos em anos específicos. Nas ocorrências relacionadas a drogas/substâncias, São Francisco se destacou como caso discrepante, com taxas muito superiores às dos demais bairros, sobretudo em 2011, 2013 e 2019; sem esse bairro, os demais apresentam valores mais baixos e comportamento mais oscilatório, com aumentos pontuais em Prado Velho, Batel e Guabirota.

Como próxima etapa, a análise temporal poderá ser complementada com o teste de *Kruskal-Wallis*, avaliando se o aumento médio anual das taxas de crimes violentos e de ocorrências relacionadas a drogas/substâncias difere entre os grupos socioeconômicos dos bairros. Além disso, será realizada uma análise de sensibilidade com e sem bairros discrepantes, como São Francisco e Jardim Botânico, para verificar se os padrões observados se mantêm.

3.3 Pergunta 3

A distribuição das ocorrências varia de acordo com o período do dia?

Hipóteses:

- Crimes violentos devem apresentar maior concentração no período da noite, pois esse intervalo pode estar associado a maior vulnerabilidade urbana, menor circulação formal de pessoas e maior ocorrência de conflitos interpessoais.

- Acidentes de trânsito e atendimentos operacionais/assistenciais tendem a ocorrer com maior frequência durante o dia, especialmente no período da tarde, quando há maior circulação de veículos, pessoas e atividades urbanas.

A hipótese de que existe associação entre o tipo de ocorrência e o período do dia é corroborada pela análise dos dados. Historicamente, em Curitiba, o total de ocorrências registradas pela SIGESGUARDA para crimes violentos é maior no período noturno, enquanto as ocorrências relacionadas a acidentes de trânsito e atendimentos operacionais/assistenciais se concentram principalmente no período da tarde. Esse resultado indica que diferentes tipos de ocorrência acompanham distintas dinâmicas de uso da cidade ao longo do dia.

4 Dados e modelos

Na etapa de aprendizado de máquina, o objetivo será construir um modelo de classificação capaz de prever o tipo de ocorrência registrada pelo SIGESGUARDA. As classes que serão preditas foram construídas por meio das colunas `NATUREZAX_DESCRICAO` ($x \in [1, 5]$), assim, essas colunas serão removidas antes da construção do modelo para evitar problema de multi-colinearidade.

As classes que serão preditas são:

- `ATENDIMENTO_OPERACIONAL_ASSISTENCIAL`;
- `ACIDENTE_TRANSITO`;
- `CRIME_PATRIMONIAL`;
- `CRIME_VIOLENTO`;
- `CRIME_ORDEM_PUBLICA`;
- `CRIME_DROGAS_SUBSTANCIAS`;
- `OUTROS`.

Para a modelagem, as classes preditoras `ACIDENTE_NATURAL`, `RISCO_ESTRUTURAL`, `EXPLOSIVOS_E_PRODUTOS_PERIGOSOS`, `MATERIAIS_OBJETOS`, `CRIME_ADMINISTRACAO_PUBLICA`, `PESSOAS_DESAPARECIDAS`, `CRIME_FRAUDE_DOCUMENTAL`, `CRIME_CRIANCA_ADOLESCENTE` e `CRIME_HONRA_DISCRIMINACAO` foram reduzidas à classe `OUTROS` por possuírem frequência no *dataset* inferior a 4% e, por se tratarem de classes raras podem interferir na qualidade do modelo final.

As colunas do *dataset* que serão utilizadas como variáveis explicativas são:

- `ATENDIMENTO_BAIRRO_NOME`;
- `FLAG_EQUIPAMENTO_URBANO`;
- `FLAG_FLAGRANTE`;
- `populacao_estimado`;
- `MADRUGADA`;
- `MANHA`;

- TARDE;
- NOITE.

Para as variáveis socioeconômicas, serão testados dois cenários: no primeiro, utilizaremos as variáveis `rendimento_medio_responsavel_sm_estimado` e `pct_alfabetizacao_15mais_estimado`, no segundo, usaremos essas duas variáveis para construir um Índice Socioeconômico Simplificado (ISE) para os bairros de Curitiba. Essa abordagem é uma aproximação da metodologia empregada por Silva et al. (2017). Para isso, cada variável será normalizada pelo método min-max, de modo que valores mais próximos de 1 indiquem melhores condições socioeconômicas. O ISE será calculado por:

$$ISE_b = \frac{RendaNorm_b + AlfabetizacaoNorm_b}{2} \quad (4)$$

Em que:

- $RendaNorm_b$ representa a variável `rendimento_medio_responsavel_sm_estimado` normalizada para o bairro b .
- $AlfabetizacaoNorm_b$ representa a variável `pct_alfabetizacao_15mais_estimado` normalizada para o mesmo bairro.

O método que atingir os melhores resultados será utilizado no modelo final.

A variável relacionada a taxa de analfabetismo não será utilizada, uma vez que é calculada por meio de `pct_alfabetizacao_15mais_estimado` e introduziria multicolinearidade ao modelo. A variável categórica `ATENDIMENTO_BAIRRO_NOME` será codificada por meio de duas tentativas: *label encoding* ordenando os bairros com base na quantidade de ocorrências que eles possuem e *one-hot encoding*, sendo a decisão final aquela que atingir o modelo com melhor capacidade classificativa.

Quanto ao modelo utilizado, será efetuada uma seleção entre os modelos: regressão logística, árvore de decisão, *random forest*, *cat boost* e *XGBoost*. O modelo que atingir a melhor performance passará por uma etapa de otimização de hiperparâmetros.

O melhor modelo será decidido com base nas métricas de qualidade estabelecidas. Como se tratam de dados desbalanceados e com múltiplas categorias, iremos analisar a métrica *F1-score macro* e matriz de confusão. O *F1-score macro* é obtido calculando o *F1* de cada classe separadamente e depois tirando a média simples. Essa métrica será utilizada porque ela nos dá o peso para todas as categorias, inclusive as classes minoritárias, não favorecendo um determinado modelo apenas porque ele acerta muito a classe mais frequente.

$$F1_{macro} = \frac{F1_1 + F1_2 + ... F1_k}{k} \quad (5)$$

onde k é o número de classes, no nosso caso $k = 7$.

A validação dos modelos será realizada inicialmente por meio da divisão dos dados em conjunto de treino e teste. Como as variáveis alvo estão desbalanceadas, será aplicada amostragem estratificada, garantindo que a proporção de cada tipo de ocorrência seja preservada nos dois conjuntos. Em seguida, os modelos serão avaliados por validação cruzada estratificada.

5 Levantamento bibliográfico

O artigo de Silva et al. (2020) contribuiu para a definição da estratégia de construção das variáveis socioeconômicas anuais utilizadas neste trabalho. Como os dados censitários disponíveis para os bairros de Curitiba correspondem principalmente aos anos de 2010 e 2022, foi necessário estimar valores para os anos intermediários e posteriores. Nesse sentido, o estudo auxiliou na compreensão da importância da interpolação e da extrapolação linear como procedimentos metodológicos para estimar informações em períodos sem observação direta.

O trabalho de Silva et al. (2017) está diretamente relacionado ao tema central deste projeto, pois também analisa a criminalidade em Curitiba a partir de uma perspectiva intraurbana, considerando diferenças sociais e territoriais entre os bairros. Esse artigo ajudou na formulação das perguntas de pesquisa e das hipóteses, especialmente na investigação sobre a possível relação entre indicadores socioeconômicos, como renda e alfabetização, e a distribuição das ocorrências criminais no espaço urbano. Além disso, o estudo contribuiu para a construção do Índice Socioeconômico Simplificado utilizado neste trabalho, inspirado na ideia de sintetizar diferentes dimensões sociais em uma única métrica comparável entre bairros.

O artigo de He e Garcia (2009) contribuiu principalmente para a etapa de aprendizado de máquina do projeto. Como o objetivo da modelagem é classificar o tipo de ocorrência registrada pela Guarda Municipal, o problema envolve múltiplas classes e uma distribuição desbalanceada, já que algumas categorias aparecem com frequência muito maior do que outras. O artigo discute justamente os desafios associados ao aprendizado com dados desbalanceados e mostra que métricas tradicionais, como a acurácia, podem favorecer modelos que classificam melhor apenas as classes majoritárias. Dessa forma, ele se relaciona ao projeto por fundamentar a escolha de métricas mais adequadas, como o *F1-score macro*, que avalia o desempenho do modelo considerando também as classes menos frequentes.

O artigo de Chen e Guestrin (2016) contribui para a etapa de modelagem preditiva deste projeto, especialmente por apresentar o *XGBoost*, um método baseado em *gradient boosting* com árvores de decisão. Esse modelo é relevante para o trabalho porque a base consolidada possui grande volume de registros e variáveis tabulares relacionadas ao bairro, período do dia, ano, indicadores socioeconômicos e características da ocorrência. Como o objetivo é classificar o tipo de ocorrência registrada pela Guarda Municipal, o *XGBoost* será avaliado como um dos modelos candidatos por sua capacidade de capturar relações não lineares e interações entre variáveis explicativas.

6 Próximos passos

- Finalizar a construção das variáveis socioeconômicas estimadas utilizando renda e alfabetização para calcular o Índice Socioeconômico Simplificado (ISE);
- Aplicar o teste estatístico de *Kruskal-Wallis*, para verificar se existem diferenças significativas nas taxas de ocorrências entre os grupos de renda e alfabetização;
- Realizar análises de sensibilidade com e sem bairros discrepantes, como São Francisco para ocorrências relacionadas a drogas e Jardim Botânico para ocorrências relacionadas a violência, avaliando se os padrões encontrados permanecem consistentes;
- Preparar a base para aprendizado de máquina, removendo colunas que causam vazamento de informação como `NATUREZAX_DESCRICA0` e `pct_analfabetismo_15mais`, além de agrupar classes raras da variável target em OUTROS;

- Codificar a variável `ATENDIMENTO_BAIRRO_NOME` utilizando *label encoding* ou *one-hot encoding*;
- Dividir os dados em conjuntos de treino e teste utilizando amostragem estratificada, preservando a proporção das classes em cada conjunto;
- Treinar e comparar diferentes modelos de classificação, como regressão logística, árvore de decisão, *random forest*, *CatBoost* e *XGBoost*;
- Avaliar os modelos por validação cruzada estratificada, utilizando o *F1-score macro* e a matriz de confusão;
- Selecionar o modelo com melhor desempenho e realizar a otimização de hiperparâmetros;
- Interpretar os resultados do modelo final, identificando quais variáveis mais contribuem para a classificação dos tipos de ocorrência;
- Organizar os resultados finais em tabelas, gráficos e mapas, relacionando os achados estatísticos, temporais, espaciais e preditivos.
- Revisar o relatório final e produzir os slides para a apresentação do projeto.

Referências

CHEN, T.; GUESTRIN, C. Xgboost: A scalable tree boosting system. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. New York, NY, USA: Association for Computing Machinery, 2016. p. 785–794.

Departamento Intersindical de Estatística e Estudos Socioeconômicos. *Perfil demográfico e socioeconômico dos bairros agregados de Curitiba*. Curitiba, 2016. Aditivo nº 21303/01 ao Contrato de Prestação de Serviços – SMTE/MC e DIEESE. Disponível em: <<https://www.coreconpr.gov.br/wp-content/uploads/2016/07/bairros.pdf>>. Acesso em: 14 abr. 2026.

HE, H.; GARCIA, E. A. Learning from imbalanced data. *IEEE Transactions on Knowledge and Data Engineering*, v. 21, n. 9, p. 1263–1284, 2009.

Instituto Brasileiro de Geografia e Estatística. *Base de informações do Censo Demográfico 2010: resultados do universo por setor censitário: documentação do arquivo*. Rio de Janeiro, 2011. Disponível em: <https://www.cidadessustentaveis.org.br/arquivos/SIG/documentacao-sig/IBGE_BR-Setores-Censitarios_Censo\%202010_Variaveis-universo.pdf>. Acesso em: 14 abr. 2026.

Laerd Statistics. *Kruskal-Wallis H Test using SPSS Statistics*. 2018. Disponível em: <<https://statistics.laerd.com/spss-tutorials/kruskal-wallis-h-test-using-spss-statistics.php>>. Acesso em: 20 abr. 2026.

MEASURE Evaluation. *Population Analysis for Planners: Lesson 6*. Disponível em: <<https://www.measureevaluation.org/resources/training/online-courses-and-resources/non-certificate-courses-and-mini-tutorials/population-analysis-for-planners/lesson-6.html>>. Acesso em: 16 abr. 2026.

NEPOMUCENO, E. G. *Interpolação, extrapolação, aproximação e ajuste de funções*. 2016. Material didático de métodos numéricos. Disponível em: <https://ufsj.edu.br/portal-repositorio/File/nepomuceno/mn/12MN_Interpola.pdf>. Acesso em: 16 abr. 2026.

PALHANO, E. N. et al. *Tutorial R: teste de Kruskal-Wallis*. 2023. Disponível em: <https://lea.estadistica.ccet.ufrr.br/tutoriais/kruskal_wallis.html>. Acesso em: 20 abr. 2026.

PROKHORENKOVA, L. et al. Catboost: Unbiased boosting with categorical features. In: *Advances in Neural Information Processing Systems*. [s.n.], 2018. v. 31, p. 6638–6648. Disponível em: <<https://papers.neurips.cc/paper/7898-catboost-unbiased-boosting-with-categorical-features>>.

SILVA, G. A. e. et al. Mortalidade por câncer nas capitais e no interior do Brasil: uma análise de quatro décadas. *Revista de Saúde Pública*, v. 54, 2020.

SILVA, M. M. d. et al. Desenvolvimento social e criminalidade: uma análise intra-urbana do fenômeno em Curitiba. In: ANPUR. *Anais do XVII Encontro Nacional da Associação Nacional de Pós-Graduação e Pesquisa em Planejamento Urbano e Regional*. São Paulo, 2017. Disponível em: <https://xviienanpur.anpur.org.br/publicacoes/XVII.ENANPUR_Anais/ST_Sessoes_Tematicas/ST%202/ST%202.9/ST%202.9-01.pdf>. Acesso em: 27 abr. 2026.

WEDEN, M. M. et al. Evaluating linearly interpolated intercensal estimates of demographic and socioeconomic characteristics of U.S. counties and census tracts 2001–2009. *Population Research and Policy Review*, v. 34, n. 4, p. 541–559, 2015.