

Relação entre ocorrências registradas pela Guarda Municipal e indicadores socioeconômicos nos bairros de Curitiba

Nome da equipe: Data BIT

Luiz Fernando de Barros Caixeta

Link para o repositório: <https://gitlab.com/luizfbcaixeta/IntroCD>

Universidade Tecnológica Federal do Paraná

Curitiba, Brasil

I. INTRODUÇÃO

Este trabalho tem como objetivo analisar a distribuição espacial e temporal das ocorrências registradas pela Guarda Municipal de Curitiba, por meio da base SIGESGUARDA, relacionando esses registros a indicadores socioeconômicos dos bairros da cidade. Para isso, foram utilizados dados do SIGESGUARDA, referentes ao período de 2009 a 2025, e dados dos Censos Demográficos de 2010 e 2022 do IBGE, considerando variáveis de população, renda, alfabetização e saneamento básico.

A análise parte da ideia de que os registros de ocorrências urbanas precisam ser interpretados em relação às características territoriais da cidade. Como bairros mais populosos ou com maior circulação de pessoas tendem a concentrar mais registros absolutos, o trabalho utiliza taxas por 10 mil habitantes, indicadores normalizados e um Índice de Qualidade de Vida, permitindo uma comparação mais equilibrada entre diferentes áreas de Curitiba.

O recorte espacial adotado corresponde aos bairros de Curitiba, segundo a divisão territorial utilizada pelo IPPUC. O trabalho foi orientado por três perguntas de pesquisa: se indicadores socioeconômicos estão associados às taxas de violência e drogas; quais bairros apresentam maior crescimento dessas taxas ao longo do tempo; e se é possível prever a quantidade mensal de ocorrências atendidas pela Guarda Municipal a partir do histórico do SIGESGUARDA.

II. DADOS, TRATAMENTO E CONSTRUÇÃO DOS INDICADORES

A base do SIGESGUARDA foi inicialmente tratada para corrigir inconsistências e padronizar os registros utilizados na análise. A variável ATENDIMENTO_BAIRRO_NOME apresentava erros de digitação, variações de grafia e registros associados a localidades externas ao município. Os nomes dos bairros foram padronizados segundo a referência territorial do IPPUC, e os registros pertencentes à Região Metropolitana de Curitiba foram excluídos da base final.

Além da padronização espacial, foram construídas variáveis sintéticas para agrupar diferentes tipos de ocorrência. A partir

das descrições registradas pelos funcionários da Guarda Municipal, os registros foram organizados em CRIME_VIOLENTO, ATENDIMENTO_OPERACIONAL_ASSISTENCIAL, ACIDENTE_DE_TRANSITO, CRIME_PATRIMONIAL, CRIME_DROGAS_SUBSTANCIAS, CRIME_ORDEM_PUBLICA e outras categorias de baixa frequência. As categorias mais raras foram reunidas na classe OUTROS, reduzindo a fragmentação da base e aumentando a estabilidade das análises.

Os dados do IBGE foram utilizados para caracterizar as condições socioeconômicas dos bairros. Foram consideradas três dimensões principais: alfabetização, renda e saneamento básico. Como os dados censitários estavam disponíveis apenas para 2010 e 2022, os valores dos demais anos foram estimados por interpolação linear nos anos intercensitários e por extrapolação linear para 2009 e para o período de 2023 a 2025. Esse procedimento permitiu compatibilizar os indicadores socioeconômicos com a série de ocorrências do SIGESGUARDA. [1].

Com o objetivo de sintetizar as condições socioeconômicas dos bairros de Curitiba, foi construído um Índice de Qualidade de Vida (IQV). O índice foi inspirado no estudo de [2], que analisa a relação entre desenvolvimento social e criminalidade em escala intraurbana em Curitiba. Antes da composição do índice, as variáveis foram normalizadas pelo método Min-Max Normalization, pois estavam em escalas diferentes. O método de normalização escolhido seguiu o que foi discutido por [3]. No caso das variáveis negativas de saneamento, a interpretação foi invertida após a normalização, de modo que valores mais altos indicassem melhores condições de vida.

O componente de saneamento foi calculado como a média das quatro variáveis normalizadas e invertidas. Em seguida, o IQV de cada bairro foi calculado pela média das três dimensões consideradas, multiplicada por 100:

$$IQV_b = \frac{100}{3} (x_{renda,b}^{norm} + x_{alfabetizacao,b}^{norm} + x_{saneamento,b}^{norm}). \quad (1)$$

Quanto maior o valor do índice, melhores são as condições socioeconômicas estimadas para o bairro. A Figura 1 apre-




Figura 1. Distribuição espacial das variáveis socioeconômicas normalizadas e do Índice de Qualidade de Vida nos bairros de Curitiba.

senta a distribuição espacial das variáveis socioeconômicas normalizadas e do IQV nos bairros de Curitiba. Observa-se que bairros periféricos apresentam, em geral, piores métricas socioeconômicas, enquanto bairros mais centrais e valorizados concentram maiores valores de renda, alfabetização e qualidade de vida. No mapa final, Batel apresentou o maior índice, enquanto Caximba apresentou o menor valor.

III. RELAÇÃO ENTRE IQV, VIOLÊNCIA E DROGAS

Para responder à primeira pergunta de pesquisa, foram realizadas regressões lineares relacionando as sete variáveis socioeconômicas resumidas pelo IQV dos bairros com as taxas por 10 mil habitantes de `CRIME_VIOLENTO` e `CRIME_DROGAS_SUBSTANCIAS`. A escolha dessas variáveis segue a proposta de [2], que também relaciona indicadores de desenvolvimento social e criminalidade em escala intraurbana.

A Figura 2 apresenta a relação entre IQV e taxa de crimes violentos por 10 mil habitantes. A regressão apresentou $p = 1,88 \times 10^{-4}$, indicando uma associação estatisticamente significativa entre as variáveis. A inclinação da reta é positiva, sugerindo que as taxas tendem a aumentar levemente conforme o IQV cresce.

Apesar da significância estatística, o valor de R^2 foi baixo ($R^2 = 1 \times 10^{-2}$). Isso significa que o IQV explica apenas cerca de 1,1% da variação observada nas taxas de crimes violentos. Portanto, a associação identificada possui baixo poder explicativo e não deve ser interpretada como relação causal direta.

A Figura 3 apresenta a relação entre IQV e taxa de ocorrências relacionadas a drogas e substâncias. Nesse caso, a regressão também apresentou significância estatística, com $p = 1,37 \times 10^{-5}$. Assim como no caso dos crimes violentos, a reta de tendência apresenta inclinação positiva, indicando uma associação estatística entre maior IQV e maior taxa registrada de ocorrências relacionadas a drogas.

No entanto, o valor de R^2 também foi baixo ($R^2 = 1,5 \times 10^{-2}$). Isso indica que o IQV explica apenas cerca de




Figura 2. Relação entre Índice de Qualidade de Vida e taxa de crimes violentos por 10 mil habitantes.




Figura 3. Relação entre Índice de Qualidade de Vida e taxa de ocorrências relacionadas a drogas e substâncias por 10 mil habitantes.

1,5% da variação das ocorrências relacionadas a drogas. Dessa forma, embora exista associação estatisticamente significativa, a maior parte da variação observada depende de outros fatores que não estão representados diretamente pelo índice.

Essa limitação é importante porque o SIGESGUARDA registra o local da ocorrência, mas não informa necessariamente o bairro de residência da pessoa que cometeu o crime nem o bairro de residência da vítima. Assim, os registros podem refletir circulação urbana, presença de equipamentos públicos, concentração de comércio e serviços, intensidade de fiscalização, operações específicas da Guarda Municipal e maior fluxo de pessoas em certas áreas da cidade.

IV. CRESCIMENTO ANUAL DAS TAXAS DE VIOLÊNCIA E DROGAS

Para responder à segunda pergunta de pesquisa, foram calculadas taxas anuais de ocorrência por 10 mil habitantes para cada bairro. Em seguida, foi calculado o crescimento médio anual dessas taxas, de modo a identificar bairros em que os registros cresceram de forma mais consistente ao longo do tempo, em vez de observar apenas anos isolados.

A Figura 4 apresenta a evolução da taxa de crimes violentos nos bairros com maior aumento médio anual, enquanto a Figura 5 apresenta a evolução da taxa de ocorrências relacionadas a drogas e substâncias. Na série de crimes violentos, o Jardim Botânico se destaca como um dos bairros com maiores taxas ao longo do período, especialmente a partir de 2013, atingindo um pico em 2021. O Prado Velho também apresenta crescimento expressivo até 2016, seguido de queda gradual nos anos posteriores. Bairros como Taboão e Batel apresentam oscilações pontuais, com picos em anos específicos, enquanto os demais bairros mantêm taxas mais baixas e variações menos intensas. Na série relacionada a drogas e substâncias, observam-se aumentos pontuais no Prado Velho em 2013 e entre 2021 e 2022, no Batel entre 2017 e 2018 e em 2022, e na Guabirotuba em 2020. De modo geral, os gráficos indicam que o crescimento médio anual pode ser influenciado tanto por tendências persistentes quanto por aumentos concentrados em períodos específicos.




Figura 4. Evolução temporal da taxa de crimes violentos por 10 mil habitantes nos bairros com maior aumento médio anual.




Figura 5. Evolução temporal da taxa de ocorrências relacionadas a drogas e substâncias por 10 mil habitantes nos bairros com maior aumento médio anual.

Os bairros com maior crescimento nas taxas de crimes violentos e drogas não correspondem necessariamente aos bairros com menor IQV. Essa diferença reforça que os registros de ocorrência não podem ser interpretados apenas como reflexo das condições socioeconômicas dos moradores. Em alguns casos, as taxas podem ser influenciadas por baixa população, maior circulação de pessoas, presença de

equipamentos urbanos, concentração de atividades noturnas, operações específicas da Guarda Municipal ou mudanças na forma de registro.

V. MODELAGEM PREDITIVA DAS OCORRÊNCIAS DO SIGESGUARDA

A terceira pergunta de pesquisa investigou se é possível prever a quantidade de ocorrências atendidas pela Guarda Municipal em determinado mês a partir do histórico de registros do SIGESGUARDA. Para isso, foi desenvolvido um processo de modelagem preditiva com os dados agregados mensalmente por bairro e categoria de ocorrência.

A unidade de análise utilizada foi a combinação entre bairro b , categoria c e mês t . A variável-alvo, representada por $y_{b,c,t}$, corresponde ao número de ocorrências registradas naquele bairro, naquela categoria e naquele mês. Dessa forma, o problema de previsão foi formulado como a estimativa de $\hat{y}_{b,c,t+1}$, isto é, a quantidade esperada de ocorrências no mês seguinte.

Antes do treinamento dos modelos, foi construído um painel mensal completo. Isso significa que todas as combinações entre bairros, meses e categorias foram representadas na base, mesmo quando não houve ocorrência registrada. Nesses casos, o valor da variável-alvo foi preenchido como zero. Esse procedimento foi necessário para evitar que o modelo aprendesse apenas a partir dos meses com ocorrência, o que poderia superestimar a frequência real dos registros.

As variáveis explicativas incluíram informações temporais, espaciais, históricas e socioeconômicas. Foram utilizadas variáveis como ano, mês, bairro, categoria da ocorrência, população estimada, IQV, defasagens temporais e médias móveis. As defasagens foram calculadas para 1, 2, 3, 6 e 12 meses, enquanto as médias móveis foram calculadas para janelas de 3, 6 e 12 meses.

Também foram incluídas variáveis cíclicas para representar a sazonalidade mensal, utilizando seno e cosseno do mês. Essa transformação permite representar o ciclo anual de forma mais adequada, já que dezembro e janeiro, embora numericamente distantes, são meses consecutivos. Essa estratégia foi utilizada principalmente nos modelos separados por categoria.

Como se trata de uma série temporal, a validação dos modelos precisou respeitar a ordem cronológica dos dados. Por isso, não foi utilizada uma divisão aleatória entre treino e teste. A divisão aleatória poderia permitir que informações futuras fossem usadas para prever períodos passados, gerando uma avaliação artificialmente otimista.

Foi adotada uma estratégia de validação temporal com janela expansiva. Inicialmente, os modelos foram treinados com os dados de 2009 a 2016 e avaliados em janeiro de 2017. Em seguida, a janela de treino foi ampliada mês a mês, utilizando todos os dados disponíveis até o mês anterior para prever o mês seguinte. Esse procedimento foi repetido até o final da série.

Foram testados modelos de baseline, modelos estatísticos e modelos de machine learning. Os baselines foram utilizados

como referência inicial de desempenho, pois permitem verificar se os modelos mais complexos realmente acrescentam capacidade preditiva em relação a regras simples baseadas no histórico da própria série. Foram avaliadas a repetição do mês anterior, médias móveis de 3, 6 e 12 meses, repetição do mesmo mês do ano anterior e média histórica. Esses modelos simples são importantes porque, em séries temporais administrativas, parte relevante do comportamento pode ser explicada pela persistência recente dos registros.

Também foi testada uma regressão de Poisson, adequada para dados de contagem. A escolha desse modelo se justifica porque a variável-alvo corresponde ao número de ocorrências registradas em determinado bairro, categoria e mês, isto é, uma variável discreta, não negativa e associada à frequência de eventos. Nesse contexto, a formulação Poisson fornece uma referência estatística coerente para comparar os modelos de machine learning, pois estima a contagem esperada de ocorrências a partir das variáveis explicativas [4]. No entanto, isso assume uma estrutura mais restrita de relação entre as variáveis explicativas e a variável-alvo, o que pode limitar seu desempenho diante de padrões não lineares, interações entre bairros, categorias e efeitos temporais.

Entre os modelos de machine learning, foram avaliados Random Forest, Extra Trees, Gradient Boosting, HistGradientBoosting com perda Poisson, TweedieRegressor e XGBoost com objetivo Poisson. Esses modelos foram testados porque conseguem capturar relações não lineares e interações entre variáveis, o que pode ser importante em dados urbanos e administrativos [5]. O XGBoost com objetivo Poisson foi incluído por combinar a flexibilidade de modelos baseados em árvores com uma função objetivo compatível com dados de contagem, mantendo as previsões no domínio de valores não negativos [6].

Nos modelos com formulação Poisson, a função de perda utilizada foi baseada na verossimilhança negativa da distribuição de Poisson, também chamada de *Poisson negative log-likelihood*. Assumindo que a variável observada y_i segue uma distribuição de Poisson com média esperada λ_i , tem-se:

$$P(Y_i = y_i | \lambda_i) = \frac{e^{-\lambda_i} \lambda_i^{y_i}}{y_i!} \quad (2)$$

A partir dessa distribuição, a função de perda pode ser escrita como a negativa da log-verossimilhança:

$$\mathcal{L}_{\text{Poisson}} = \sum_{i=1}^n (\lambda_i - y_i \log(\lambda_i) + \log(y_i!)) \quad (3)$$

em que y_i representa o número real de ocorrências observadas e λ_i representa a contagem esperada prevista pelo modelo.

Essa escolha foi adequada porque a variável-alvo do trabalho representa o número de ocorrências registradas em cada combinação de bairro, categoria e mês, assumindo sempre valores inteiros e não negativos. Assim, a função objetivo Poisson evita tratar a previsão como um problema de regressão contínua comum e torna o treinamento mais coerente com a natureza dos dados analisados.

As métricas utilizadas foram MAE, RMSE, WAPE e BIAS. O MAE mede o erro médio absoluto, indicando, em média, quantas ocorrências o modelo erra em suas previsões. O RMSE também mede o erro médio, mas penaliza mais fortemente erros grandes. O WAPE mede o erro absoluto total em relação ao total de ocorrências observadas, sendo útil para comparar categorias com volumes diferentes. O BIAS indica se o modelo tende a superestimar ou subestimar os valores reais.

A Tabela I apresenta uma comparação entre os baselines, os modelos globais avaliados e as versões do XGBoost Poisson. De modo geral, observa-se que os baselines já apresentaram desempenho competitivo, especialmente a média móvel de 6 meses, que apresentou o menor WAPE da comparação. Entre os modelos globais de machine learning, o Extra Trees apresentou os menores valores de MAE e RMSE.

Tabela I
COMPARAÇÃO DOS MODELOS DE PREVISÃO DAS OCORRÊNCIAS MENSIS DO SIGESGUARDA.

Modelo	MAE	RMSE	WAPE	BIAS	Real	Prev.
Baseline mês anterior	3,00	8,18	39,67%	-0,54%	376,438	369,083
Baseline média 3m	2,85	8,79	36,91%	-1,10%	376,438	366,027
Baseline média 6m	2,84	8,76	36,47%	-2,15%	376,438	362,038
Baseline ano anterior	4,29	15,11	54,48%	-6,90%	376,438	343,613
Baseline média histórica	4,77	16,52	59,08%	-34,12%	376,438	224,500
Extra Trees	2,96	8,39	37,97%	0,45%	399,123	398,171
Gradient Boosting	2,69	8,70	38,62%	1,44%	399,123	401,894
Hist. Grad. Boosting Poisson	2,72	9,02	38,93%	1,05%	399,123	400,408
Random Forest	2,72	8,45	38,94%	2,96%	399,123	408,427
XGBoost Poisson	2,76	11,86	35,59%	-0,65%	376,438	373,980
XGBoost Poisson otimizado	2,76	11,80	35,68%	-1,26%	376,438	371,692

Os resultados indicam que os modelos mais complexos apresentaram ganhos pequenos em relação aos baselines. A média móvel de 6 meses foi o melhor baseline global, sugerindo que o histórico recente das ocorrências contém informação importante para a previsão.

A otimização de hiperparâmetros do XGBoost Poisson foi realizada por meio de busca aleatória, avaliando 20 combinações de parâmetros. Essa estratégia foi escolhida porque permite explorar diferentes configurações do modelo sem testar exaustivamente todas as combinações possíveis, o que reduziria a viabilidade computacional da etapa de ajuste. A otimização foi feita separadamente por categoria, considerando uma validação temporal para preservar a ordem cronológica da série. Foram avaliados hiperparâmetros como número de estimadores, taxa de aprendizado, profundidade máxima das árvores, peso mínimo por folha, amostragem das linhas, amostragem das colunas, regularização L1 e L2, penalização de partições, além de parâmetros associados ao controle dos passos de atualização do modelo.

Apesar da etapa de ajuste, o desempenho agregado do XGBoost Poisson otimizado foi muito próximo ao modelo anterior. Houve pequena redução no RMSE, de 11,86 para 11,80, mas o WAPE passou de 35,59% para 35,68%. Assim, a otimização não produziu uma melhora expressiva no erro relativo agregado.




Figura 6. Comparação entre valores reais e previstos pelos modelos selecionados por categoria.

A Tabela II apresenta o desempenho do XGBoost Poisson otimizado por categoria. Observa-se que as categorias com maior volume de registros, como ATENDIMENTO_OPERACIONAL_ASSISTENCIAL e ACIDENTE_TRANSITO, apresentaram melhor desempenho relativo. Já CRIME_DROGAS_SUBSTANCIAS e CRIME_ORDEM_PUBLICA foram mais difíceis de prever, apresentando WAPE mais elevado.

Tabela II
DESEMPENHO DO XGBOOST POISSON OTIMIZADO POR CATEGORIA DE OCORRÊNCIA.

Categoria	MAE	RMSE	WAPE	BIAS
ATENDIMENTO_OPERACIONAL_ASSISTENCIAL	7,03	24,45	31,11%	0,03%
ACIDENTE_TRANSITO	4,19	14,56	33,87%	-4,82%
CRIME_PATRIMONIAL	1,65	2,72	41,24%	-0,04%
CRIME_VIOLENTO	1,63	2,69	41,65%	-0,07%
CRIME_ORDEM_PUBLICA	1,19	1,98	54,92%	-0,38%
CRIME_DROGAS_SUBSTANCIAS	0,88	2,63	63,20%	1,20%

A Figura 6 apresenta a comparação entre os valores reais e previstos para os modelos selecionados por categoria. Observa-se que os modelos acompanham razoavelmente as tendências gerais das séries com maior volume de registros, como atendimentos operacionais e assistenciais, acidentes de trânsito e crimes patrimoniais. No entanto, os picos abruptos são mais difíceis de prever, especialmente quando ocorrem mudanças rápidas no padrão da série.

De modo geral, os modelos tendem a suavizar as previsões, aproximando-se da tendência média das séries. Esse comportamento é esperado em modelos treinados com histórico mensal, pois eventos extremos podem depender de fatores que não estão presentes na base. Mudanças operacionais da Guarda Municipal, eventos urbanos específicos, alterações na forma de registro, operações localizadas e variações na circulação

de pessoas podem influenciar o número de ocorrências sem que essas informações estejam representadas nas variáveis utilizadas.

VI. CONCLUSÃO GERAL

Este trabalho buscou integrar dados públicos, indicadores socioeconômicos e registros administrativos da Guarda Municipal de Curitiba para analisar a distribuição espacial e temporal das ocorrências urbanas. A combinação entre SIGESGUARDA e dados do IBGE permitiu construir uma base territorializada, com informações anuais e mensais por bairro, possibilitando tanto análises exploratórias quanto modelagem preditiva.

Em relação à primeira pergunta de pesquisa, os resultados indicaram que o IQV apresentou associação estatisticamente significativa com crimes violentos e ocorrências relacionadas a drogas. No entanto, os valores de (R^2) foram baixos, mostrando que o índice possui baixo poder explicativo.

Essa limitação decorre, em parte, da própria estrutura da base de dados. O SIGESGUARDA registra o bairro onde a ocorrência foi atendida, mas não informa necessariamente o bairro de residência ou o contexto socioeconômico cotidiano das pessoas envolvidas. Dessa forma, o IQV utilizado na regressão corresponde ao território do registro, e não necessariamente ao território de origem dos autores, vítimas ou solicitantes. Por isso, os resultados podem refletir não apenas as condições socioeconômicas dos moradores do bairro, mas também fluxos territoriais, circulação urbana, presença de equipamentos públicos, concentração de comércio e serviços, atividades noturnas, intensidade de fiscalização, operações

específicas da Guarda Municipal e maior fluxo de pessoas em determinadas áreas da cidade.

Em relação à segunda pergunta, a análise temporal permitiu identificar bairros com maior crescimento médio anual das taxas de violência e drogas. No caso dos crimes violentos, destacaram-se bairros como Jardim Botânico e Prado Velho, além de oscilações pontuais em bairros como Taboão e Batel. No caso das ocorrências relacionadas a drogas, bairros, como Prado Velho, Batel e Guabirota, apresentaram aumentos localizados.

Em relação à terceira pergunta, a modelagem preditiva mostrou que é possível prever parcialmente as ocorrências mensais atendidas pela Guarda Municipal. Os modelos de machine learning, especialmente o XGBoost Poisson por categoria, apresentaram o melhor desempenho agregado. Ainda assim, os resultados indicam que o modelo não deve ser interpretado como uma ferramenta capaz de prever o número exato de ocorrências em cada bairro e categoria. Sua contribuição principal está na estimativa da ordem de grandeza esperada dos registros, permitindo identificar tendências gerais, categorias com maior volume provável de atendimentos e áreas que podem demandar maior atenção operacional.

Dessa forma, o modelo pode funcionar como uma ferramenta de apoio ao planejamento da Guarda Municipal. Ao indicar padrões esperados de ocorrência ao longo do tempo e entre bairros, a previsão pode auxiliar na distribuição de equipes pela cidade, na organização de escalas, na definição de áreas prioritárias e no acompanhamento de mudanças no comportamento das séries.

REFERÊNCIAS

- [1] M. M. Weden, C. E. Peterson, J. N. V. Miles, and R. A. Shih, "Evaluating linearly interpolated intercensal estimates of demographic and socioeconomic characteristics of u.s. counties and census tracts 2001–2009," *Population Research and Policy Review*, vol. 34, no. 4, pp. 541–559, 2015.
- [2] M. M. d. Silva, L. A. Torrens, M. C. I. Schafaschek, and V. L. Miozzo, "Desenvolvimento social e criminalidade: uma análise intra-urbana do fenômeno em Curitiba," in *Anais do XVII Encontro Nacional da Associação Nacional de Pós-Graduação e Pesquisa em Planejamento Urbano e Regional*. São Paulo: ANPUR, 2017. [Online]. Available: https://xviienanpur.anpur.org.br/publicacoes/XVII.ENANPUR_Anais/ST_Sessoes_Tematicas/ST%202/ST%202.9/ST%202.9-01.pdf
- [3] S. G. K. Patro and K. K. Sahu, "Normalization: A preprocessing stage," 2015. [Online]. Available: <https://arxiv.org/abs/1503.06462>
- [4] T. Liboschik, K. Fokianos, and R. Fried, "tscount: An R package for analysis of count time series following generalized linear models," *Journal of Statistical Software*, vol. 82, no. 5, pp. 1–51, 2017.
- [5] K. Schimohr, P. Doebler, and J. Scheiner, "Prediction of bike-sharing trip counts: Comparing parametric spatial regression models to a geographically weighted xgboost algorithm," *Geographical Analysis*, vol. 55, no. 4, pp. 651–684, 2023.
- [6] T. Chen and C. Guestrin, "Xgboost: A scalable tree boosting system," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, ser. KDD '16. New York, NY, USA: Association for Computing Machinery, 2016, pp. 785–794.
- [7] G. A. e. Silva, B. C. Jardim, V. d. M. Ferreira, W. L. Junger, and V. R. Girianelli, "Mortalidade por câncer nas capitais e no interior do Brasil: uma análise de quatro décadas," *Revista de Saúde Pública*, vol. 54, 2020.
- [8] H. He and E. A. Garcia, "Learning from imbalanced data," *IEEE Transactions on Knowledge and Data Engineering*, vol. 21, no. 9, pp. 1263–1284, 2009.
- [9] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, and A. Gulin, "Catboost: Unbiased boosting with categorical features," in *Advances in Neural Information Processing Systems*, vol. 31, 2018, pp. 6638–6648. [Online]. Available: <https://papers.nips.cc/paper/7898-catboost-unbiased-boosting-with-categorical-features>
- [10] Laerd Statistics, "Kruskal-wallis h test using SPSS statistics," Lund Research Ltd, 2018. [Online]. Available: <https://statistics.laerd.com/spss-tutorials/kruskal-wallis-h-test-using-spss-statistics.php>
- [11] E. N. Palhano *et al.*, "Tutorial R: teste de Kruskal-Wallis," Laboratório de Estatística Aplicada, Universidade Federal do Rio Grande do Norte, 2023. [Online]. Available: <https://lea.estadistica.ccet.ufrn.br/tutoriais/kruskal-wallis.html>
- [12] E. G. Nepomuceno, "Interpolação, extrapolação, aproximação e ajuste de funções," Universidade Federal de São João del-Rei, 2016, material didático de métodos numéricos. [Online]. Available: https://ufsj.edu.br/portal-repositorio/File/nepomuceno/mn/12MN_Interpola.pdf
- [13] MEASURE Evaluation, "Population analysis for planners: Lesson 6," Carolina Population Center, University of North Carolina at Chapel Hill. [Online]. Available: <https://www.measureevaluation.org/resources/training/online-courses-and-resources/non-certificate-courses-and-mini-tutorials/population-analysis-for-planners/lesson-6.html>
- [14] Instituto Brasileiro de Geografia e Estatística, *Base de informações do Censo Demográfico 2010: resultados do universo por setor censitário: documentação do arquivo*, IBGE, Rio de Janeiro, 2011. [Online]. Available: https://www.cidadessustentaveis.org.br/arquivos/SIG/documentacao-sig/IBGE_BR-Setores-Censitarios_Censo%202010_Variaveis-universo.pdf
- [15] Departamento Intersindical de Estatística e Estudos Socioeconômicos, "Perfil demográfico e socioeconômico dos bairros agregados de Curitiba," Observatório do Trabalho de Curitiba, Curitiba, Estudo temático 2, 2016, aditivo nº 21303/01 ao Contrato de Prestação de Serviços – SMTE/MC e DIEESE. [Online]. Available: <https://www.coreconpr.gov.br/wp-content/uploads/2016/07/bairros.pdf>